

電子情報通信実験IV－2

時系列解析と予測

担当 村松

1. 目的

- モノのインターネット
(IoT: Internet of Things)が普及
 - 多種多様なデータが取得されるようになった
- 本テーマでは,
 - 時間情報を付与されたランダムに変動するデータ, 時系列を扱う
 - 有益な情報を得るために必要な時系列解析, 特に自己回帰モデルの分析と予測の基礎理論を学ぶ
 - 実習を通して現象の分析と予測の技法を身に付ける

2. 解説

- 時系列解析(time-series analysis)
 - 時系列:
時間の経過とともに不規則に変動する現象の記録
 - 気圧や気温などの気象情報
 - 地震波の記録
 - 株価や為替レート
 - 脳波や心電図
 - 自動車やロボットの操縦記録
- 時系列の図示や統計量などの「**記述**」, 変動の特徴を表現する「**モデリング**」, 過去データからの将来の変動の「**予測**」を行うなどの統計的手法

時系列解析の分類

単純

- 等間隔時系列
- 単変量時系列
- 定常時系列
- ガウス型時系列
- 線形時系列


複雑

- 不等間隔時系列
- 多変量時系列
- 非定常時系列
- 非ガウス型時系列
- 非線形時系列

本テーマでは主として単純な時系列の解析を扱う

時系列の例

- $\{y_1, y_2, \dots, y_N\}$



2. 1 共分散関数

- 定常時系列のもっとも基本的な特徴表現
 - 自己共分散関数(単変量時系列の統計量):
過去の変動との関連の強さを表す
 - 相互共分散関数(多変量時系列の統計量):
他の時系列の変動との関連の強さを表す
- 時系列の定常性
 - 平均, 分散, 共分散
時間をシフトしても変化しない

自己共分散関数 (単変量時系列の統計量)

- 平均値関数

$$\mu_n = E[y_n]$$

- 分散関数

$$\text{Var}(y_n) = E[(y_n - \mu_n)^2]$$

- 自己共分散関数

$$\text{Cov}(y_n, y_{n-k}) = E[(y_n - \mu_n)(y_{n-k} - \mu_{n-k})]$$

- 自己相関関数

$$\rho_k = \frac{\text{Cov}(y_n, y_{n-k})}{\sqrt{\text{Var}(y_n)}\sqrt{\text{Var}(y_{n-k})}}$$

範囲 $[-1, 1]$

(弱)定常過程

- 平均値関数が時刻 n によらず一定

$$\mu_n = \mu$$

- 共分散関数がラグ(時差) k のみに依存

$$\text{Cov}(y_n, y_{n-k}) = \gamma_k$$

- 自己相関関数

$$\rho_k = \frac{\gamma_k}{\gamma_0}$$

相互共分散関数 (多変量時系列の統計量)

- 平均ベクトル

$$\boldsymbol{\mu} = \begin{pmatrix} \mu[1] \\ \mu[2] \\ \vdots \\ \mu[M] \end{pmatrix} = E[\mathbf{y}_n] = E \left[\begin{pmatrix} y_n[1] \\ y_n[2] \\ \vdots \\ y_n[M] \end{pmatrix} \right]$$

- 相互共分散関数

$$\mathbf{C}_k = E[(\mathbf{y}_n - \boldsymbol{\mu})(\mathbf{y}_{n-k} - \boldsymbol{\mu})^T] = \begin{pmatrix} \gamma_k[1,1] & \gamma_k[1,2] & \cdots & \gamma_k[1,M] \\ \gamma_k[2,1] & \gamma_k[2,2] & \cdots & \gamma_k[2,M] \\ \vdots & \vdots & \ddots & \vdots \\ \gamma_k[M,1] & \gamma_k[M,2] & \cdots & \gamma_k[M,M] \end{pmatrix}$$

ただし, $\gamma_k[\ell, m] = E[(y_n[\ell] - \mu[\ell])(y_{n-k}[m] - \mu[m])]$

- 相互相関関数

$$\mathbf{R}_k = \boldsymbol{\Lambda}^{-\frac{1}{2}} \mathbf{C}_k \boldsymbol{\Lambda}^{-\frac{1}{2}}$$

ただし, $\boldsymbol{\Lambda} = \text{diag}(\gamma_0[1,1], \gamma_0[2,2], \dots, \gamma_0[M,M])$

時系列 $y_n[\ell]$ の
自己共分散関数

観測標本からの推定

- 長さ N の時系列 $\{y_1, y_2, \dots, y_N\}$ が観測されたとき
 - 標本平均ベクトル

$$\hat{\mu} = \frac{1}{N} \sum_{n=1}^N y_n$$

単変量時系列の場合は
 $M = 1$ と考える

- 標本相互共分散関数


$$\hat{\mathbf{C}}_k = \begin{pmatrix} \hat{\gamma}_k[1,1] & \hat{\gamma}_k[1,2] & \cdots & \hat{\gamma}_k[1,M] \\ \hat{\gamma}_k[2,1] & \hat{\gamma}_k[2,2] & \cdots & \hat{\gamma}_k[2,M] \\ \vdots & \vdots & \ddots & \vdots \\ \hat{\gamma}_k[M,1] & \hat{\gamma}_k[M,2] & \cdots & \hat{\gamma}_k[M,M] \end{pmatrix} = \frac{1}{N} \sum_{n=k+1}^N (y_n - \hat{\mu})(y_{n-k} - \hat{\mu})^T$$

不偏標本分散の場合は
 $N - 1$ で割る

- 標本相互相関関数

$$\hat{\mathbf{R}}_k = \hat{\mathbf{\Lambda}}^{-\frac{1}{2}} \hat{\mathbf{C}}_k \hat{\mathbf{\Lambda}}^{-\frac{1}{2}}$$

ただし, $\hat{\mathbf{\Lambda}} = \text{diag}(\hat{C}_0[1,1], \hat{C}_0[2,2], \dots, \hat{C}_0[M,M])$



2. 2 ARMAモデル

- 時系列解析などの統計解析
データはある確率分布に従う確率変数の実現値とみなす
 - 時系列モデルはこの確率分布を観測データに基づいて推定
- 自己回帰移動平均 (ARMA) モデル
 - 単変量の時系列 y_n を過去の観測値 $\{y_{n-1}, y_{n-2}, \dots, y_{n-p}\}$ と白色ノイズ $\{w_n, w_{n-1}, \dots, w_{n-q}\}$ の線形和で表現

$$y_n = \sum_{\ell=1}^p a_{\ell} y_{n-\ell} + w_n - \sum_{\ell=1}^q b_{\ell} w_{n-\ell}$$

- 自己回帰係数: a_{ℓ} (p は自己回帰の次数)
- 移動平均係数: b_{ℓ} (q は移動平均の次数)

ARモデル

- 自己回帰(autoregressive)モデル

$$y_n = \sum_{\ell=1}^p a_{\ell} y_{n-\ell} + w_n$$

- ユール・ウォーカー方程式

$$\gamma_k = \sum_{\ell=1}^p a_{\ell} \gamma_{k-\ell} + \text{Cov}(w_n, w_{n-k})$$

ただし,


$$\text{Cov}(w_n, w_{n-k}) = \begin{cases} \sigma^2 & k = 0 \\ 0 & k \neq 0 \end{cases}$$

- $\gamma_0, \gamma_1, \dots$ に対応するAR(p-1) およびAR(p)モデルの係数 a_{ℓ}^{p-1} と a_{ℓ}^p のユール・ウォーカー解の関係

$$a_{\ell}^p = a_{\ell}^{p-1} - a_p^p a_{p-\ell}^{p-1}, (\ell = 1, 2, \dots, p-1)$$

白色ガウスノイズ

AR(p)モデル



移動平均係数が零
のARMAモデル

a_p^p : AR(p)モデルの偏自己相関係数
(PARCOR)

AR係数の推定

- $\gamma_0, \gamma_1, \dots$ からのAR(p)モデルの係数 $a_1^p, a_2^p, \dots, a_p^p$ の推定(←線形重回帰)
【同等】 p 次までのPARCOR $a_1^1, a_2^2, \dots, a_p^p$ の推定(←レビンソンーダービン)
- 特性方程式

$$a(D) = 1 - \sum_{\ell=1}^p a_{\ell} D^{\ell} = 0$$

- 根がすべて単位円の外側にある場合は定常
(すべてのPARCORの絶対値 <1)

- ADF検定 (H_0 を棄却する誤り確率 p 値 $>$ 有意水準)

- 帰無仮説 $H_0: \rho = 1$ (単位根過程)
- 対立仮説 $H_1: 0 < \rho < 1$ (弱定常過程)

※ARの次数 p とは別もの

単位根過程でも1次階差系列 $\Delta y_n = y_n - y_{n-1}$ は
定常かもしれない

VARモデル

- ベクトル自己回帰(VAR)モデル
ARモデルを多変量時系列に一般化

$$\mathbf{y}_n = \sum_{\ell=1}^p \mathbf{A}_{\ell} \mathbf{y}_{n-\ell} + \mathbf{w}_n$$

VAR(p)モデル

- $\mathbf{y}_n$ が M 次元の場合, $\mathbf{A}_{\ell}$ は $M \times M$ 係数行列
 - $\mathbf{w}_n$ は M 次元白色ガウスノイズ
- 特性方程式

$$A(D) = \det \left(\mathbf{I} - \sum_{\ell=1}^p \mathbf{A}_{\ell} D^{\ell} \right) = 0$$

- すべての解の絶対値が1より**大きい**: 定常条件

2. 3 (線形)状態空間モデル

- さまざまな時系列モデルを統一的に取り扱い可能
 - 定常過程のほか, 非定常過程も取り扱い可能

$$\begin{aligned} \mathbf{x}_n &= \mathbf{F}_n \mathbf{x}_{n-1} + \mathbf{G}_n \mathbf{v}_n \\ \mathbf{y}_n &= \mathbf{H}_n \mathbf{x}_n + \mathbf{w}_n \end{aligned}$$

- $\mathbf{x}_n$: 状態 (K 次元ベクトル)
- $\mathbf{v}_n$: システムノイズ (L 次元ベクトル)
- $\mathbf{w}_n$: 観測ノイズ (M 次元ベクトル)
- $\mathbf{F}_n$: 推移行列 ($K \times K$ 行列)
- $\mathbf{G}_n$: 係数行列 ($K \times L$ 行列)
- $\mathbf{H}_n$: 観測行列 ($M \times K$ 行列)

AR(p)モデルの状態空間表現

- 状態ベクトル

$$\mathbf{x}_n = \begin{pmatrix} y_n \\ (a_2 y_{n-1} + \dots + a_p y_{n-p+1}) \\ \vdots \\ (a_{p-1} y_{n-1} + a_p y_{n-2}) \\ a_p y_{n-1} \end{pmatrix}$$


- 推移行列, 係数行列, 観測行列

$$\mathbf{F}_n = \begin{pmatrix} a_1 & 1 & \dots & 0 & 0 \\ a_2 & 0 & \ddots & 0 & 0 \\ \vdots & \vdots & & \vdots & \\ a_{p-1} & 0 & \dots & 0 & 1 \\ a_p & 0 & \dots & 0 & 0 \end{pmatrix}, \mathbf{G}_n = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \\ 0 \end{pmatrix}, \mathbf{H}_n = (1 \quad 0 \quad \dots \quad 0 \quad 0)$$

- システムノイズ v_n の分散 $\mathbf{Q}_n = \sigma^2$
- 観測ノイズ w_n の分散 $\mathbf{R}_n = 0$

状態の推定

- 時系列 y_n の観測値から状態 x_n を推定することが重要
 - 予測: $\ell < n$
 - フィルタ: $\ell = n$
 - 平滑化: $\ell > n$



カルマンフィルタ

- 線形ガウス型状態空間モデルでの推定
 - 平均ベクトルと分散共分散行列のみを更新
- k 期先長期予測

$$\begin{aligned}\mathbf{x}_{n+k|n} &= \mathbf{F}_{n+k} \mathbf{x}_{n+k-1|n} \\ \mathbf{V}_{n+k|n} &= \mathbf{F}_{n+k} \mathbf{V}_{n+k-1|n} \mathbf{F}_{n+k}^T + \mathbf{G}_{n+k} \mathbf{Q}_{n+k} \mathbf{G}_{n+k}^T \\ \mathbf{y}_{n+k|n} &= \mathbf{H}_{n+k} \mathbf{x}_{n+k|n} \\ \mathbf{U}_{n+k|n} &= \mathbf{H}_{n+k} \mathbf{V}_{n+k|n} \mathbf{H}_{n+k}^T + \mathbf{R}_{n+k}\end{aligned}$$

- 観測データ $\mathbf{Y}_{1:\ell}$ を条件とした状態 $\mathbf{x}_n$ の
 - 平均ベクトル
 - 分散共分散行列

$$\mathbf{x}_{n|\ell} = \mathbf{E}[\mathbf{x}_n | \mathbf{Y}_{1:\ell}]$$

$$\mathbf{V}_{n|\ell} = \mathbf{E} \left[(\mathbf{x}_n - \mathbf{x}_{n|\ell})(\mathbf{x}_n - \mathbf{x}_{n|\ell})^T \right]$$

3. 予習内容

- サンプルデータ“[example02_01_2026.wav](#)”(2026年度版)を配信する。時系列データ(階差系列) y_{diff} の開始から1秒間のデータに関して以下の課題に取り組むこと。(GitHub: [example01_01.ipynb](#) / [example02_01.ipynb](#)参照)
 1. 定常性を仮定して平均 μ と分散 γ_0 を推定せよ
 2. 定常性を仮定して自己共分散関数 γ_k と自己相関関数 ρ_k を推定せよ
- グループワークに利用可能な時系列データの候補を挙げよ(討論の準備をせよ)
 - オープンデータ, 既出論文からのデータ, もしくは研究室や個人的に取得した実測データ

4. 実施内容

1. (個人ワーク) サンプル時系列データを配信する。原系列 y_n と差分系列(1次階差系列) Δy_n に対し以下の解析を行え。
 - a. 原系列 y_n と差分系列 Δy_n のグラフをプロットせよ。
 - b. 差分系列 Δy_n のADF 検定の結果, p 値が0.05 以下であることを確認し, 差分系列 Δy_n のAR モデルを構築せよ。AR モデルの次数 p をAIC 最小化法により決定せよ。
 - c. b.で得たARモデルの残差(residual)とそのPARCOR をプロットせよ。
 - d. カルマンフィルタとしてb.のAR モデルを構築し, 長期予測を行え。
2. (グループワーク) 選定した時系列データに対してカルマンフィルタによる長期予測とその評価を実施せよ。なお, ARモデルに限る必要はない。
 - a. 利用する時系列の前半をモデル構築に利用し, 後半を予測との比較に利用せよ。
 - b. 実測データと予測データを重ねてグラフにプロットせよ。

サンプルコードとデータの配信

- サンプルコードについて
 - 以下のGitHubサイトにて公開
<https://github.com/msiplab/EicEngLabIV>
- サンプルデータについて
 - 上記GitHubで公開(dataフォルダ内)
- 実験用データについて
 - 学務情報システムレポート課題添付予定(5/1)

5. 報告事項

1. (個人ワーク) グラフプロットから解析対象となる時系列とARモデルについて考察せよ。
2. (グループワーク) カルマンフィルタを利用した長期予測の実習について以下の内容を報告せよ。
 - a. 利用したデータに関して報告せよ。
 - b. カルマンフィルタを利用した長期予測に関して考察せよ。
3. 以下の用語について各自調査して報告せよ。
 - a. トレンド(trend)成分
 - b. 季節(seasonality)成分
 - c. 粒子フィルタ(particle filter)
 - d. データ同化(data assimilation)
 - e. 異常検知(anomaly detection)

報告の際の注意

- 時系列分析について
 - 利用した時系列分析法を明記すること
 - モデルの種類
 - モデルパラメータ
- グラフについて
 - 内容に合わせたタイトル
 - 各軸のラベル(単位を忘れずに)
 - 必要に応じて凡例(legend)

(補足) グループワークについて

- データ収集の例
 - 研究室等の実験データ
 - MATLAB Mobile データ(補足資料参照)
 - 「オープンデータ」「open data」などネット検索
 - Statsmodelsデータセットを利用
<https://www.statsmodels.org/stable/datasets/index.html>
 - Kaggle データセットを利用
<https://www.kaggle.com/datasets>